



# percepção

MAC318 - INTRODUÇÃO À PROGRAMAÇÃO DE ROBÔS MÓVEIS


parte 3

# incerteza é prevalente

- Ruído
  - Medidas imprecisas e pouco confiáveis
- Observabilidade parcial
  - Estado completo do mundo desconhecido
- Ação
  - Resultados podem ser inesperados ou não determinísticos

# tipos de incertezas


- **Percepção**: diferença entre valor real e valor medido / estimado
- **Ação**: diferença entre resultado pretendido e resultado obtido
- **Erro sistemático**
  - podem a princípio serem reduzidos
- **Erro aleatório**
  - não podem ser reduzidos



# sensor de distância ultrassônico

## modelo de raio


- Erros sistemáticos
  - cone de dispersão
  - ecos, reflexão especular, tempo de resposta, velocidade relativa alvo/robô, temperatura, superfície etc.
- Erros aleatórios
  - ruído (imprecisão  $\pm 3\text{cm}$ )
  - imprecisão do mapa



# sensor de distância ultrassônico


## modelo de raio

- Cone de dispersão
  - posicionado no eixo do sensor na parte cinza
  - em geral,  $10^\circ \leq \theta_2 \leq 25^\circ$
- distância =  $\frac{\text{medida} \times \cos(\theta_1)}{\cos(\theta_1 + \theta_2)}$
- reflexão especular: sem medição se ângulo de incidência for superior a  $2\theta_2$



# mapas de linhas

- distância até objeto mais próximo em uma dada pose pode ser obtida pelo método `range` da classe `LineMap`




```
Line[] lines = { new Line(x11,y11,x12,y12), new Line(x21,y21,x22,y22) };  
Rectangle bounds = new Rectangle(0, 0, largura, altura);  
LineMap mymap = new LineMap(lines, bounds);
```

```
Pose mypose = (10, 20, 120);  
mymap.range(pose);           // retorna 12
```

# cálculo da medida esperada

- valor **esperado** da medida do sonar pode ser calculado “simulando” cone de dispersão





```
Pose tmppose = (30, 25, 120);  
float esperado = Float.POSITIVE_INFINITY;  
for (int angulo=-teta2; angulo <= teta2; angulo++) {  
    tmppose.setHeading(mypose.getHeading() - angulo);  
    float dist = mymap.range(tmpPose);  
    if (dist > 0 && dist < esperado) esperado = dist;  
} // esperado = 11
```



# atividade 1: modelo de raio

- baixa código com modelo de raio para sonar
  - dados pose do sonar, mapa de linhas, ângulo  $\theta_2$ , computar medida esperada
- usar código para estimar valor de  $\theta_2$ 
  - fazer uma varredura na pose (43,67,-90) e escolher ângulo  $\theta_2$  que minimiza erro quadrático médio no intervalo [10,25]
- escrever código que desenha **mapa local esperado** na interface do sonar



outlier



# atividade 1: modelo de raio


pose	esperado	medido	erro	erro quadrático
(70,20,0)	19.5	19	0.5	0.25
(70,20,2)	19.8	18	-1.8	3.24
(70,20,4)	20.6	20	0.6	0.36
(70,20,6)	21.0	23	2	4
(70,20,8)	21.4	55	33.6	1128.2





# atividade 1: modelo de raio

- entregar relatório contendo
  - gráficos mostrando erro quadrático para cada valor de  $\theta_2$  testado
  - discussão sobre possíveis pontos descartados
    - sugestão: erro absoluto maior que 10 cm
  - gráfico mostrando mapa local esperado para  $\theta_2$  escolhido e medidas tomadas




# atividade 1: modelo de raio



- (43,67,-90)
- $\theta_2 = 17$



# atividade 1: modelo de raio




- (63,67,90)

- $\theta_2 = 21$

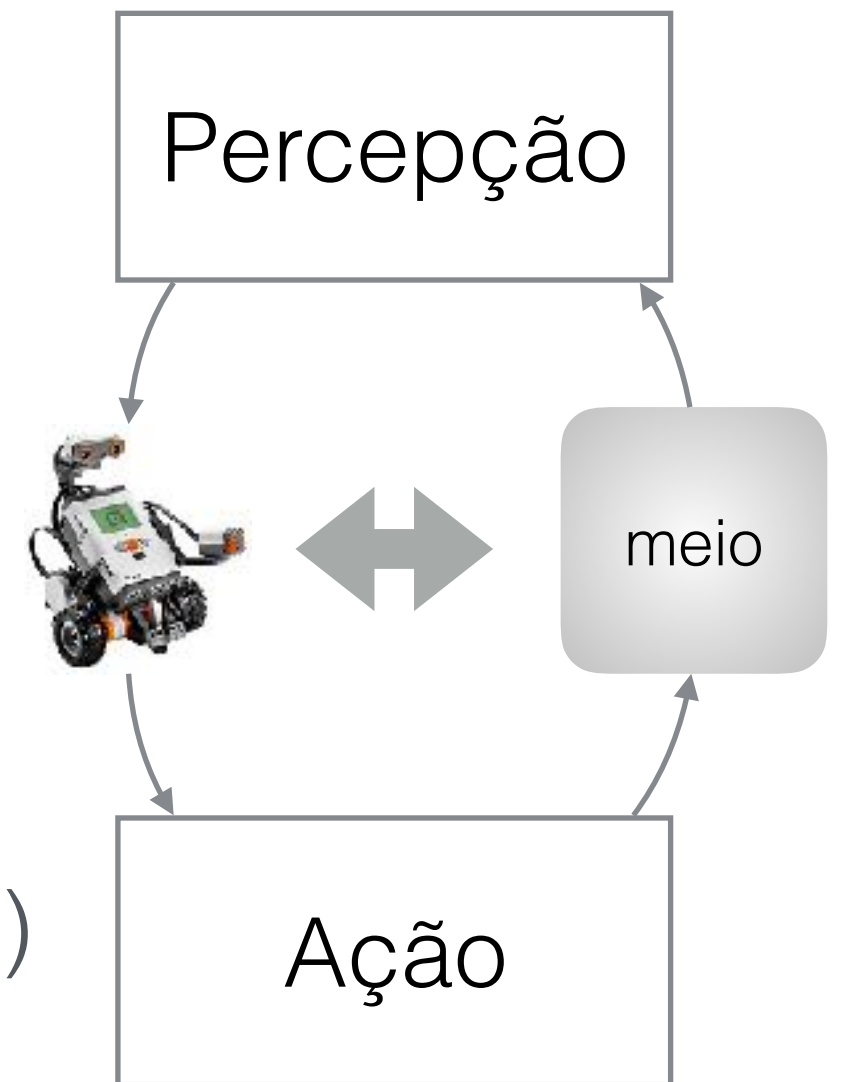
# erros aleatórios

- Não podem ser reduzidos
- Mas podem ser modelados
- Abordagem lógica
  - considera “mundos possíveis”
- **Abordagem probabilística**/estatística
  - atribui “pesos/preferências” a mundos possíveis



# modelo probabilístico

- Modelo de percepção
  - $P(\text{sensor}|\text{estado do mundo})$
- Modelo de ação
  - $P(\text{estado}'|\text{ação}, \text{estado do mundo})$




# probabilidades

- Álgebra de eventos

- $A \subseteq \Omega = \text{universo}$

- $A \cup B, A', A \cap B$



- Subjetivismo:  $P(A)$  denota nossa crença que A é verdade

- $0 \leq P(A) \leq 1, \quad P(\Omega) = 1, \quad P(A') = 1 - P(A)$



- Aditividade: Se  $A_1 \cup A_2 \cup \dots$  é um evento, e  $A_i \cap A_j = \emptyset$  então

- $P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$




# variável aleatória

- Mapeia cada evento  $A \in \Omega$  em um valor real
- Distribuição de probabilidades:
  - $P(x_0 < X \leq x_1) = P(A: x_0 < X(A) \leq x_1)$
  - $P(X = x) = P(x < X \leq x) = [\text{se contínuo}] = 0$
- Função de densidade:
  - $P(x_0 < X \leq x_1) = \int_{(x_0, x_1]} p(x) dx$
  - $p(x) \geq 0$  e  $\int_{(-\infty, \infty)} p(x) dx = 1$



# Expectativa

- Valor esperado ( $\neq$  valor mais provável)
- $E[X] = \sum x \cdot P(X=x)$  ou  $\int_{(-\infty, \infty)} x \cdot p(x) dx$   
discreto contínuo
- $E[aX + b] = a \cdot E[X] + b$




# variância

- Medida de **dispersão**
  - $\text{Var}[X] = E[(X-E[X])^2] = E[X^2] - E[X]^2$
  - $\text{Var}[X-c] = \text{Var}[X]$




pequena



grande

# variável gaussiana

$$p(x) = \mathcal{N}(\mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$



$$E[X] = \mu$$

$$\text{Var}[X] = \sigma^2$$


# variável gaussiana

- Estimativa de variância e média a partir de dados


$$\mu = \frac{1}{N} \sum_{i=1}^N x_i$$

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N - 1} = \frac{1}{N - 1} \sum_{I=1}^N x_i^2 - \mu^2$$

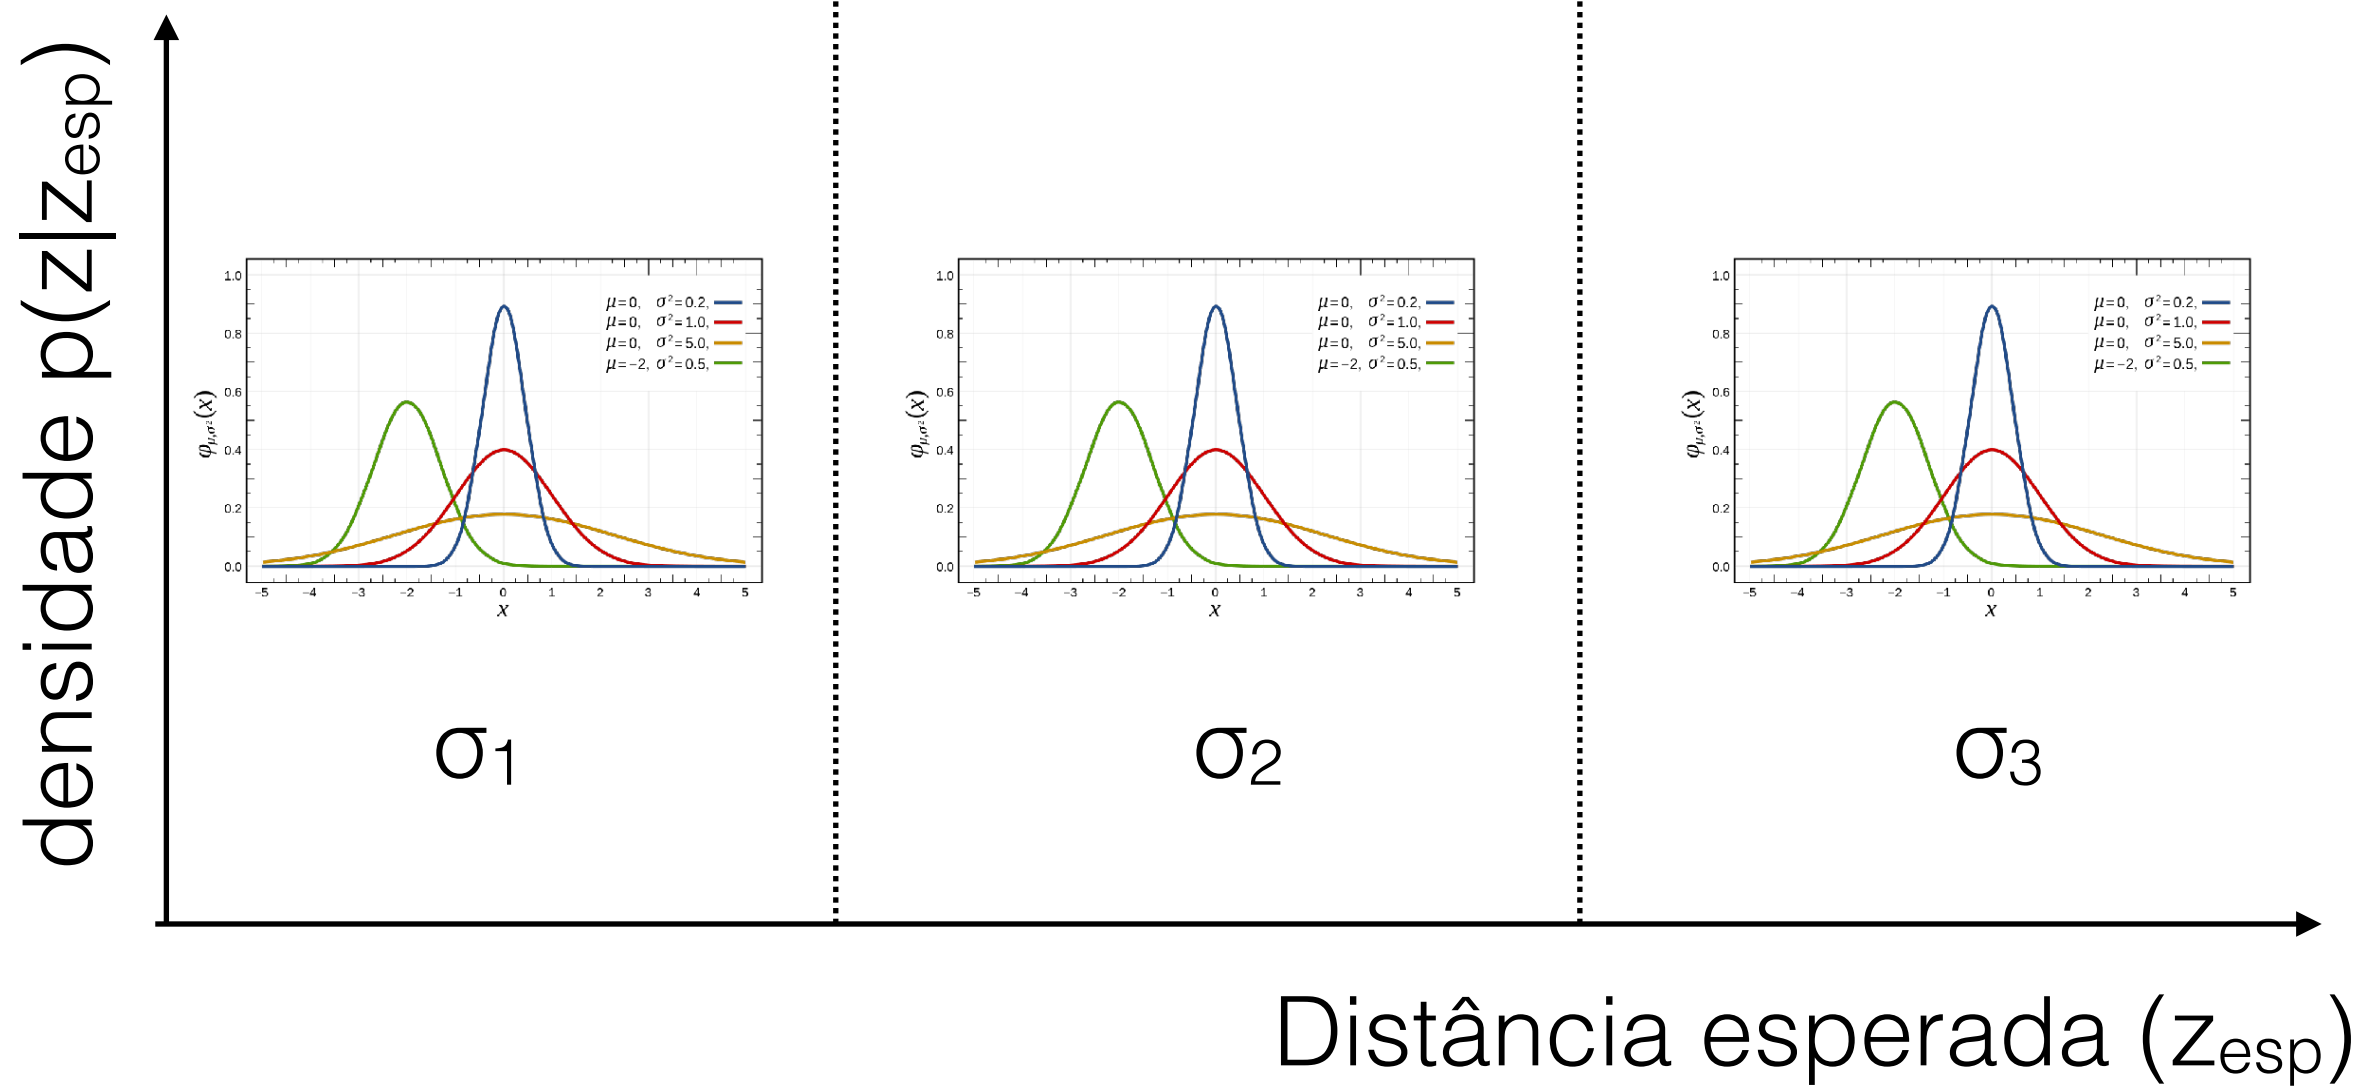
# modelo de percepção de sensor de distância ultrassônico



$$p(\text{Sensor}=10 \mid \text{pose, mapa}) \\ = \mathcal{N}(\mu_{12}, \sigma^2)$$



# faixas





# atividade 2: modelo de incerteza



- obter modelo de **erro aleatório** do sonar
  - gaussiana condicional na medida esperada
  - ignorar medidas  $\geq 255$  e com erro “grande” (ex.  $>10\text{cm}$ )
  - medir em 5 poses
    - $(5,68,-90)$  ,  $(20,68,-90)$ ,  $(40,68,-90)$ ,  $(60,68,-90)$  e  $(100,68,-90)$
- Estimar faixas e variância da gaussiana em cada faixa

# atividade 2: modelo de incerteza

- entregar relatório contendo
  - histograma de erros (com e sem pontos descartados)
  - gráfico mostrando erro por medida esperada
  - discussão sobre pontos descartados, no. de faixas e valores de variância
  - gráficos mostrando gaussiana  $p(\text{medido}|\text{esperado})$  para cada faixa


# atividade 2: modelo de incerteza

- usando dados de 5 varreduras:
- erro por medida esperada
- 2 ou 3 faixas visuais
- não muito confiável pois temos muito mais medidas na faixa de 50 - 70cm



# atividade 2: modelo de incerteza

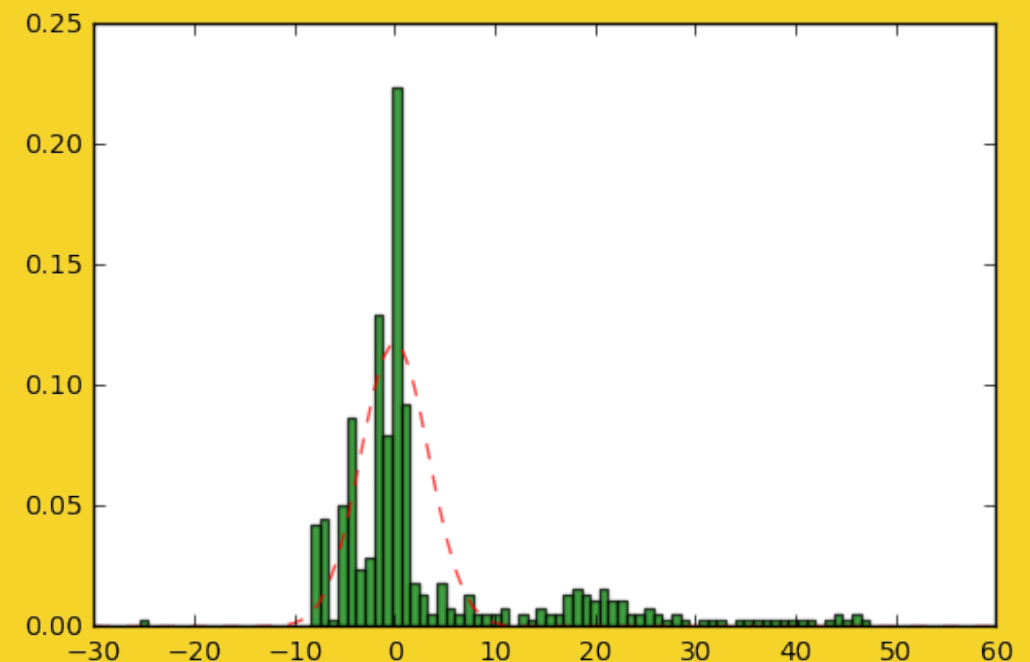

- usando 1 faixa:
  - $\sigma=3$



- considerando apenas pontos com  $|\text{erro}| < 10$

# atividade 2: modelo de incerteza


- usando 2 faixas:
  - distância esperada  $< 50\text{cm}$ 
    - $\sigma=2.87$
  - distância esperada  $\geq 50\text{cm}$ 
    - $\sigma=3.37$



- considerando apenas pontos com  $|\text{erro}| < 10$


# atividade 2: modelo de incerteza

- modelo escolhido:
  - 1 faixa
  - $\sigma=3$



# modelo de incerteza aperfeiçoado


imprecisão do sensor    medição aleatória    distância máxima



$$p_{\text{objeto}} = \mathcal{N}(z_{\text{esp}}, \sigma^2)$$

distância ao objeto  
mais próximo


+



$$p_{\text{outros}} = \mathcal{U}(z_{\min}, z_{\max})$$

erros diversos  
(ecos, reflexões etc)

+



$$p_{\text{limites}}$$

limite do sensor



# modelo de incerteza

medido

postura (x,y,θ)

mapa

$$p(z|x, m) = \omega_{\text{objeto}} p_{\text{objeto}}(z|x, m) + \omega_{\text{outros}} p_{\text{outros}}(z|x, m) + \omega_{\text{limites}} p_{\text{limites}}(z|x, m)$$

$$\omega_{\text{objeto}}, \omega_{\text{outros}}, \omega_{\text{limites}} \geq 0, \omega_{\text{objeto}} + \omega_{\text{outros}} + \omega_{\text{limites}} = 1$$

calculado

$$p_{\text{objeto}}(z|x, m) = \mathcal{N}(z_{\text{esperado}}, \sigma^2) \propto \exp \left( -\frac{(z - z_{\text{esperado}})^2}{2\sigma^2} \right)$$

$$p_{\text{outros}} = \mathcal{U}(z_{\min}, z_{\max}) = \begin{cases} \frac{1}{z_{\max} - z_{\min}}, & \text{se } z_{\min} \leq z \leq z_{\max} \\ 0, & \text{caso contrário} \end{cases}$$

$$p_{\text{limites}}(z|x, m) = \begin{cases} 1, & \text{se } z = z_{\max} \\ 0, & \text{se } z \neq z_{\max} \end{cases}$$

limite

ajuste parâmetros para maximizar probabilidade dos dados

# modelo de incerteza

- Assume independência de tipos de erros
- Não modela reflexo especular, objetos pequenos etc.
- Parâmetros devem ser ajustados a fim de maximizar probabilidade de observar dados (verossimilhança)
- Distâncias esperadas podem ser pré-computadas e memorizadas (se necessário)

# (log) verossimilhança

$$\begin{aligned}\ln p(z_1, \dots, z_N | x_1, y_1, \theta_1, \dots, x_N, y_N, \theta_N) \\&= \ln \prod_{i=1}^N p(z_i | x_i, y_i, \theta_i) \\&= \sum_{i=1}^n \ln p(z_i | x_i, y_i, \theta_i)\end{aligned}$$

Abordagem comum: Estimador  $\theta$  de máxima verossimilhança

# estimador de máxima verossimilhança

$$\sum_{i=1}^N \ln p(z_i | x_i, y_i, \sigma) = -N \ln \sigma - N \ln \sqrt{2\pi} - \sum_{i=1}^N (x_i - \mu_i)^2$$

derivando em relação à  $\sigma$  e igualando a zero (por quê?)

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu_i)^2$$

# estimador de máxima verossimilhança



modelo de incerteza do sonar

$$p(z|x, m) = \omega_{\text{objeto}} p_{\text{objeto}}(z|x, m) + \omega_{\text{outros}} p_{\text{outros}}(z|x, m) + \omega_{\text{limites}} p_{\text{limites}}(z|x, m)$$

devido à soma de componentes, não há  
formula fechada para maximizar estimação  
de parâmetros por verossimilhança

alternativa: métodos numéricos

# Primeiro passo: Estimação “visual”



$$p(z|z_{\text{exp}}) = 0.8\mathcal{N}(0, 4) + 0.15\mathcal{U}(0, 255) + 0.05\delta(z - 255)$$

# expectation-maximization

- gerar estimativa inicial para  $\omega_{\text{objeto}}$ ,  $\omega_{\text{outros}}$ ,  $\omega_{\text{lim}}$  e  $\sigma^2_{\text{objeto}}$
- repita até convergência (incremento em log verossimilhança pequeno)
  - para cada medida  $z_1, \dots, z_N$ 
    - $\eta = 1/[p_{\text{objeto}}(z_i) + p_{\text{outros}}(z_i) + p_{\text{limites}}(z_i)]$
    - $e_{i,\text{objeto}} = \eta p_{\text{objeto}}(z_i)$
    - $e_{i,\text{outros}} = \eta p_{\text{outros}}(z_i)$
    - $e_{i,\text{limites}} = \eta p_{\text{limites}}(z_i)$
  - $\omega_{\text{objeto}} = (\sum_i e_{i,\text{objeto}})/N$ ,  $\omega_{\text{outros}} = (\sum_i e_{i,\text{outros}})/N$ ,  $\omega_{\text{lim}} = (\sum_i e_{i,\text{lim}})/N$
  - $\sigma^2_{\text{objeto}} = (\sum_i e_{i,\text{objeto}}(z_i - z_{i,\text{esp}})^2)/(\sum_i e_{i,\text{objeto}})$



# atividade 3: modelo de incerteza

- estimar parâmetros de modelo de incerteza (aperfeiçoado): coeficientes  $\omega$  e variância da Gaussiana
- usar modelo para determinar “outliers”
- usar modelo para calcular probabilidade da medida para diversas poses (incluindo pose correta)



# atividade 3: modelo de incerteza

- Entregar relatório contendo:
  - parâmetros do modelo estimado
  - gráficos mostrando cada componente e densidade resultante
  - histograma de dados
- Entregar código:
  - calculando parâmetros do modelo (E-M)
  - estendendo interface para colorir medidas no mapa local de acordo com sua probabilidade

# Para próxima aula (27/11)

- Estudar aulas 1,2,3,4 do curso IA para robótica do Udacity (Introdução e filtro de Kalman)
- <https://br.udacity.com/course/artificial-intelligence-for-robotics--cs373/>